

El núcleo mínimo del chino

Rojas Lam, G. D.¹

¹2do año. Facultad de Física. Universidad de La Habana. Cuba.

E-mail: german.drojas@estudiantes.uh.cu

Tutor(es): Dr. Alejandro Lage¹

¹Centro de Sistemas Complejos, Facultad de Física, UH

Resumen

Se aplica el análisis de redes complejas al vocabulario del chino mandarín para identificar un subconjunto mínimo de caracteres que maximiza la cobertura del corpus bisilábico analizado. A partir del diccionario CEDICT y del corpus SUBTLEX-CH se construye un grafo ponderado donde los nodos son caracteres y las aristas representan su co-ocurrencia en palabras de dos caracteres. Sobre esta red se resuelve el problema WDkS (Weighted Densest k -Subgraph) mediante una relajación gran canónica que reduce el problema NP-duro a una secuencia de cortes mínimos, y se calculan métricas de centralidad (grado, intermediación). Los resultados revelan una estructura de núcleo-periferia: aproximadamente 1045 caracteres (17 % del total) cubren el 89 % del peso de la red. Los caracteres con mayor intermediación, como 子, 大 y 人, presentan alta combinatoriedad posicional, lo que sugiere que su aprendizaje temprano podría facilitar la inferencia de compuestos. Se propone un modelo pedagógico jerarquizado basado en centralidad estructural y se discute su relación con los niveles del examen HSK.

Palabras clave: redes complejas, chino mandarín, WDkS, betweenness, aprendizaje L2.

1. Introducción

El chino mandarín es una lengua que desafía las estrategias convencionales de aprendizaje de vocabulario. Los diccionarios extensos recogen decenas de miles de caracteres, pero el uso cotidiano se concentra en unos pocos miles: un hablante nativo educado reconoce típicamente entre 4000 y 6000, y con alrededor de 2000 es posible desenvolverse en la vida diaria. La recomendación tradicional de estudiar los caracteres en orden de frecuencia desaprovecha la naturaleza fuertemente composicional del idioma[1], donde la mayoría de las palabras son compuestos de dos o tres caracteres. En consecuencia, un carácter como 子 (*zi*), que aparece como sufijo en cientos de palabras frecuentes, puede ser pedagógicamente más valioso que una partícula gramatical muy usada pero con una función estructural menos compacta en el grafo bisilábico, como 的 (*de*).

Esta intuición puede formalizarse mediante la teoría de redes complejas[2]: si modelamos los caracteres como nodos y su co-ocurrencia en palabras como aristas ponderadas, las métricas de centralidad permiten cuantificar la importancia estructural de cada carácter, y problemas de optimización como el Weighted Densest k -Subgraph (WDkS) identifican los subconjuntos que maximizan la cobertura del idioma con el menor número posible de caracteres. En este trabajo construimos y analizamos el grafo de co-ocurrencia de caracteres del chino a partir del diccionario CEDICT y del corpus SUBTLEX-CH de frecuencias reales. Hemos optado por trabajar exclusivamente con palabras de dos caracteres porque, como se comprueba en la (Fig. 1),

son las más frecuentes tanto en el diccionario como en el uso real, concentrando el 80 % de los ítems. Esta restricción metodológica debe tenerse siempre presente: los resultados se refieren al vocabulario bisilábico y no al idioma completo.




Figura 1: Distribución de la longitud de las palabras en el diccionario CEDICT (azul) y en el corpus de frecuencias SUBTLEX-CH (verde). Las palabras de dos caracteres dominan ambos conjuntos, justificando la restricción a esta longitud.

2. Datos y construcción del grafo

Utilizamos dos recursos complementarios. El diccionario CEDICT[3] contiene 124 406 entradas con su forma simplificada, tradicional, pronunciación y traducción; de él extrajimos las 58 850 palabras de exacta-

mente dos caracteres, que constituyen la longitud más productiva del chino. Para ponderar las conexiones recurrimos al corpus SUBTLEX-CH[4], que lista la frecuencia de 99 121 palabras a partir de subtítulos de películas, reflejando así el registro coloquial real.

Combinando ambos, construimos el grafo no dirigido $G_2 = (V, E, w)$ donde V es el conjunto de 6 167 caracteres distintos; una arista $\{a, b\}$ existe si a y b aparecen juntos en al menos una palabra del diccionario; y el peso $w(a, b)$ es la suma de las frecuencias SUBTLEX-CH de todas las palabras que contienen ambos caracteres (si una palabra del diccionario no aparece en SUBTLEX-CH, no contribuye al peso). El peso total de la red asciende a $W_{\text{tot}} \approx 1,158 \times 10^7$, que interpretamos como una medida agregada de co-ocurrencia ponderada en el habla coloquial.

Para entender la estructura de la red de caracteres, construimos también un grafo de palabras inspirado en los juegos de palabras de Lewis Carroll. ¿En qué consiste este juego? Imaginemos que tenemos dos palabras en español, como “CASA” y “CATA”. Ambas difieren en exactamente una letra (la S por la T). El juego de Carroll consiste en transformar una palabra en otra cambiando una sola letra por paso, siempre formando palabras válidas en cada intermediario. Por ejemplo: CASA $\rightarrow$ CATA $\rightarrow$ MATA $\rightarrow$ MATE. En cada paso solo cambia una letra y el resultado es siempre una palabra real del idioma.

En nuestro caso, aplicamos esta idea al chino: dos palabras de dos caracteres se conectan si difieren en exactamente un carácter. Por ejemplo, 大人 (*dàrén*, adulto) y 大学 (*dàxué*, universidad) están conectadas porque comparten el primer carácter 大 y difieren en el segundo. De forma similar, 孩子 (*háizi*, niño) y 桌子 (*zhuōzi*, mesa) están conectadas porque comparten el segundo carácter 子 y difieren en el primero.

Tomamos las 10 000 palabras más frecuentes del corpus SUBTLEX-CH, pero solo conservamos aquellas que además aparecen en el diccionario CEDICT como palabras de exactamente dos caracteres. De este modo garantizamos que cada nodo del grafo corresponde a una palabra válida y bien documentada del idioma. Este filtro reduce el conjunto a 6 774 nodos. Esta red, que denominamos G_{Carroll} , tiene aristas entre palabras que difieren en exactamente un carácter; su peso total es unas tres veces mayor que el de G_2 , pero como veremos, su capacidad de concentración de peso es mucho menor.

3. Topología de la red de caracteres

A pesar de contar con miles de nodos, G_2 es una red compacta y altamente conectada: todos los nodos pertenecen a la misma componente gigante, el grado medio es $\approx 19,7$, aunque la distribución de grado es muy heterogénea, con una larga cola que refleja la presencia de hubs hiperconectados. El coeficiente de agrupamiento promedio es bajo ($\langle C \rangle = 0,087$), un valor típico de redes jerárquicas donde pocos nodos centrales conectan comunidades periféricas. El radio de la red es solo 5

saltos, con un diámetro de alrededor de 10.

Las métricas de centralidad revelan una clara asimetría morfológica. La Tabla 1 recoge los cinco caracteres con mayor intermediación (*betweenness*). En todos ellos, el grado entrante y el saliente difiere notablemente, lo que permite clasificarlos según su combinatoria posicional: 子, por ejemplo, recibe 639 conexiones entrantes y solo 37 salientes, confirmando su papel como sufijo productivo en palabras como 孩子 (hijo), 桌子 (mesa) o 椅子 (silla); por el contrario, 大 (grande) emite 342 conexiones salientes, comportándose como un prefijo que genera términos como 大人 (adulto), 大学 (universidad) o 大概 (probablemente). Este comportamiento no se aprecia en una lista de frecuencias puras, donde 子 aparece en la posición 8 y 大 en la 12, mientras que 的, la partícula más frecuente, ocupa el primer puesto pero tiene una intermediación 155 veces menor.

Tabla 1: Caracteres con mayor intermediación y su perfil de grado (entrante/saliente).

Carácter	Betweenness	Grado total	k_{in}	k_{out}
子	0.027	676	639	37
大	0.021	422	80	342
水	0.017	385	224	161
人	0.016	414	307	107
头	0.016	346	266	80

Las distribuciones de grado y betweenness (Fig. 2) contrastan fuertemente entre G_2 y G_{Carroll} . En G_2 el grado presenta cola larga hacia valores altos y la correlación grado-betweenness es fuerte ($r \approx 0,85$); en G_{Carroll} la distribución es más simétrica y concentrada, reflejando una conectividad homogénea sin hubs morfológicos definidos.




Figura 2: Estadísticas de centralidad. **Izquierda:** G_2 (red de caracteres) — distribución de grado, $\log_{10}(\text{betweenness})$, y dispersión grado vs betweenness. **Derecha:** G_{Carroll} (red de palabras) — mismos paneles. La asimetría de G_2 contrasta con la homogeneidad de G_{Carroll} .

4. El problema WDkS y su solución

El *Weighted Densest k-Subgraph* (WDkS) busca, dado un grafo ponderado $G = (V, E, w)$ y un entero k , el subconjunto $S \subseteq V$ con $|S| = k$ que maximice la suma de pesos de las aristas internas $\sum_{i,j \in S} w_{ij}$. Es un problema NP-duro, por lo que empleamos una relajación gran canónica [5].

La idea es mapear el problema a un modelo de Ising ferromagnético: a cada nodo i se le asigna una variable de spin $s_i \in \{-1, +1\}$, donde $s_i = +1$ indica que el nodo pertenece al subconjunto seleccionado. La energía del sistema incluye un término de interacción ferromagnética $J_{ij} = w_{ij}/4$ que favorece que nodos conectados compartan el mismo spin, y un campo externo h que controla el tamaño del subconjunto:

$$H = - \sum_{\langle i,j \rangle} J_{ij} s_i s_j - h \sum_i s_i, \quad J_{ij} = \frac{w_{ij}}{4}. \quad (1)$$

Variando h de valores muy negativos (pocos nodos seleccionados) a muy positivos (todos seleccionados), y resolviendo en cada paso un corte mínimo en la red de flujo asociada (lo cual es polinomial), obtenemos la curva completa de cobertura $P(m)$ en función de la fracción de nodos $m = k/N$.

5. El núcleo mínimo

La Fig. 3 muestra el resultado para G_2 , representando el porcentaje de peso *no cubierto* frente al número de caracteres k . Elegimos trabajar con porcentajes en lugar de cifras absolutas porque la pregunta relevante no es “¿cuántos caracteres hay que aprender?”, sino “¿qué fracción del total de caracteres necesito para dominar una fracción determinada del idioma?”. Una analogía útil es la de invitar amigos a una fiesta: no buscamos un número fijo de invitados, sino el grupo más compacto que garantice que las conversaciones (las aristas de la red) cubran la mayor parte de los temas posibles.

La curva muestra que la eficiencia de la selección óptima es abrumadora respecto a una elección proporcional (línea discontinua): mientras que una selección aleatoria del 17 % de los caracteres cubriría, en promedio, solo el 17 % del peso, la solución WDkS alcanza el 89.3 %. El punto de máxima curvatura (codo) se localiza en $k^* = 1045$ caracteres, que representan apenas el

16.9 % del total. Con 1010 caracteres (16.4 %) se llega al 80 % de cobertura, y con 1082 (17.5 %) al 90 %. Estas cifras definen un *núcleo mínimo* extremadamente compacto del chino coloquial.




Figura 3: Resultados del WDkS para G_2 . **(a)** Eficiencia de selección óptima (escala log en k); el punto verde marca el codo óptimo ($k^* \approx 1045$). **(b)** Saturación del vocabulario: peso acumulado vs número de caracteres. **(c)** Ganancia marginal por carácter adicional. **(d)** Comparación de estrategias: WDkS (azul), greedy por grado (naranja) y aleatorio (verde).

6. Comparación con otras estrategias y con la red de Carroll

Para evaluar la utilidad del WDkS lo contrastamos con dos métodos más simples: la selección voraz (*greedy*) por grado, que añade los nodos en orden decreciente de grado, y una selección completamente aleatoria. Sorprendentemente, la curva voraz es casi idéntica a la del WDkS (Fig. 3d), lo que se explica por la fuerte correlación entre grado y peso en esta red: los hubs morfológicos (子, 大, 人) son a la vez los nodos más conectados y los que acumulan las aristas de mayor frecuencia. Esto limita la ventaja práctica del WDkS sobre el simple ordenamiento por grado en el grafo de caracteres, pero valida que los métodos basados en conectividad capturan la esencia del problema. Más que una ganancia metodológica, el WDkS ofrece aquí un

marco formal que confirma la optimalidad de la estrategia voraz.

La comparación con el grafo de Carroll refuerza esta interpretación (Fig. 4). En G_{Carroll} la concentración de peso es mucho menor: para alcanzar el 80 % de cobertura se necesita más del 40 % de los nodos, y la curva no presenta un codo tan pronunciado. El codo se ubica en 1923 palabras (28.4 %) con apenas 69.3 % de cobertura. La diferencia radica en que en G_2 los caracteres actúan como verdaderos “átomos” del lenguaje, mientras que en la red de palabras completas las aristas unen vocablos que solo difieren en un carácter, dando lugar a una conectividad más homogénea.




Figura 4: Curvas WDKS: G_2 (caracteres, azul) vs G_{Carroll} (palabras, verde). La red de caracteres concentra el peso de forma mucho más eficiente.




Figura 5: WDKS para G_{Carroll} . La menor concentración de peso se manifiesta en un codo menos pronunciado y mayor fracción de nodos necesaria para coberturas equivalentes.

7. Implicaciones para la enseñanza del chino

Los resultados permiten articular un modelo pedagógico que prioriza la centralidad estructural, pero es crucial distinguir entre la importancia de un nodo en la red y su prioridad didáctica real, la cual debe validarse con criterios externos (cobertura en textos independientes, facilidad de aprendizaje, transferencia).

Con esa cautela, en una primera fase un estudiante podría aprender los caracteres con mayor intermediación —子, 大, 人, 水, 头—, que actúan como “multiplicadores léxicos” por su alta combinatoriedad posicional; con apenas cinco caracteres se adquiere la capacidad de inferir el significado de decenas de compuestos comunes. En una segunda fase, conviene explicitar la función morfológica de cada carácter, distinguiendo sufijos (alto in-degree), prefijos (alto out-degree) y núcleos semánticos (grado balanceado). Finalmente, el núcleo de unos 1000 caracteres constituye la base sobre la que se pueden construir especializaciones temáticas (medicina, ciencia, política), ya que a partir de ese punto la adición de caracteres periféricos contribuye poco a la cobertura del idioma general.

Este núcleo se relaciona de manera natural con los niveles del examen oficial HSK [6]. Según la clasificación vigente, el nivel básico (HSK 1-2) maneja 150–300 palabras, el intermedio (HSK 3-4) 600–1200 y el avanzado (HSK 5-6) 2500–5000 o más. Aunque el HSK cuenta palabras y nuestro estudio se basa en caracteres, el conjunto de 1045 caracteres permite formar un vocabulario bisilábico que supera ampliamente el umbral intermedio, lo que sugiere que una selección basada en centralidad estructural podría acelerar la adquisición de las competencias exigidas.

8. Conclusiones

Se construyó y analizó el grafo de co-ocurrencia de 6167 caracteres chinos, ponderado por la frecuencia de uso en el corpus coloquial SUBTLEX-CH y restringido a palabras de dos caracteres. La red exhibe una arquitectura de núcleo-periferia muy marcada, con un reducido conjunto de hubs morfológicos que dominan la conectividad global. La solución del problema WDKS revela que unos 1045 caracteres (el 16.9 % del total) bastan para cubrir el 89.3 % del peso total, lo que constituye un núcleo mínimo del vocabulario bisilábico hablado.

Las métricas de centralidad, especialmente la intermediación, capturan la importancia combinatoria de un carácter mejor que la frecuencia bruta, pues identifican los caracteres con alta productividad posicional que habilitan la inferencia léxica. Si bien en este grafo el algoritmo voraz por grado iguala el desempeño del WDKS debido a la correlación grado-peso, el enfoque de redes aporta un marco cuantitativo sólido para optimizar el orden de aprendizaje y abre la puerta a estudios comparativos en otros idiomas y registros.

Recomendaciones

Los resultados abren varias líneas de trabajo futuro. En primer lugar, sería valioso extender el análisis a palabras de tres y cuatro caracteres, que aunque menos frecuentes, pueden modificar la estructura del núcleo. En segundo lugar, la validación empírica del modelo pedagógico propuesto mediante ensayos controlados con estudiantes de chino como segunda lengua permitiría

cuantificar la ganancia real de aprendizaje. Finalmente, la comparación con otras lenguas aglutinantes o composicionales (coreano, japonés) podría revelar invariantes universales en la estructura del vocabulario mínimo.

Referencias

- [1] Packard, J. L. (2000). *The Morphology of Chinese*. Cambridge University Press.
- [2] Newman, M. E. J. (2010). *Networks: An Introduction*. Oxford University Press.
- [3] CC-CEDICT. <https://cc-cedict.org/>.
- [4] Cai, Q. y Brysbaert, M. (2010). SUBTLEX-CH: Chinese word and character frequencies. *PLoS ONE* **5**(6), e10729.
- [5] Wang, J. y Li, H. (2020). Weighted dominating k -set problem. *Physica A* **553**, 124219.
- [6] Centro de Estudios Chinos. ¿Cuáles son los niveles del HSK? <https://share.google/gVNRAnJ2Gn4y0fpIe>.